

Samia Carchaf . Jarvis Consulting

Titulaire d'une maîtrise en informatique spécialisée en intelligence artificielle (UQAC) et d'un diplôme d'ingénieur en génie logiciel (Polytech Tours), je développe mon expertise en développement Python, en apprentissage automatique et en ingénierie des données à travers des projets concrets chez Jarvis Consulting Group. J'ai acquis une solide expérience avec Python, SQL, PostgreSQL, Docker, Bash et Linux pour bâtir des solutions de collecte de données, d'automatisation et d'infrastructure. Ce qui me passionne, c'est d'utiliser l'IA pour rendre le développement logiciel plus intelligent, non pas comme une finalité, mais comme un outil intégré à ma pratique.

Skills

Proficient: Python, Apprentissage automatique, Linux/Bash, SGBDR/SQL, Docker, Git

Competent: Agile/Scrum, Power BI, Modélisation de données, Databricks, Apache Spark

Familiar: Java, Azure ML, AWS, MLflow, Tableau

Jarvis Projects

Project source code: https://github.com/jarviscanada/jarvis_data_eng_SamiaCarchaf

Surveillance de cluster [GitHub]:

- Conception et mise en oeuvre d'un agent de surveillance de cluster Linux pour collecter les spécifications matérielles et les données d'utilisation des ressources en temps réel sur des serveurs Linux.
- Provisionnement d'une base de données PostgreSQL avec Docker pour un stockage persistant.
- Automatisation de la collecte continue de données chaque minute via crontab, permettant une surveillance en temps réel du cluster pour l'équipe LCA.

SGBDR et SQL [GitHub]:

- Conception et mise en oeuvre d'un schéma de base de données relationnelle avec PostgreSQL, en appliquant les principes de normalisation et en garantissant l'intégrité des données via des clés primaires, des clés étrangères et des contraintes.
- Rédaction de requêtes SQL optimisées pour répondre à des questions d'affaires.

Analyse de données en Python [GitHub]:

- Construction d'un pipeline d'analyse Python de bout en bout sur la base de données des plaintes consommateurs du CFPB (États-Unis).
- Réalisation du profilage, du nettoyage et de l'ingénierie des caractéristiques des données avec Pandas, incluant la segmentation par palier d'entreprise et l'analyse des tendances temporelles.
- Production de visualisations interactives couvrant 7 constats clés, incluant la concentration du marché, l'évolution du mix de produits et une grille d'évaluation de la responsabilité du Bureau à sept dimensions.

Spark [GitHub]:

- Provisionnement d'un cluster Hadoop sur GCP Dataproc et mise en place d'une table externe Hive sur HDFS pour stocker le jeu de données World Development Indicators (WDI) (~21,7 millions de lignes).
- Rédaction d'opérations PySpark DataFrame dans un notebook Zeppelin, utilisant le filtrage, les agrégations groupBy et les jointures.
- Analyse des tendances historiques de croissance du PIB par pays, incluant l'identification de l'année de croissance maximale du PIB pour chaque pays via des transformations DataFrame.

Databricks [GitHub]:

- Construction d'un pipeline ETL par lots dans Azure Databricks pour l'analyse de détection de fraude, en intégrant les données de transactions, cartes, utilisateurs, marchands et étiquettes de fraude depuis Azure SQL Database et ADLS Gen2 vers une architecture médaillon Bronze/Silver/Gold, produisant 6 tables Gold pour un tableau de bord d'analyse de fraude Databricks.
- Construction d'un pipeline DLT (Lakeflow Declarative Pipelines) ingérant quotidiennement des données boursières depuis l'API Alpha Vantage, calculant des métriques de tendance de prix et de volume sur 7/30/90 jours à l'aide de fonctions de fenêtrage Spark.

- Application du suivi des changements SCD Type 1, conception de tables de streaming vs vues matérialisées selon les patrons de mise à jour des données, et sécurisation des identifiants API via des Databricks secret scopes.
- Orchestration des deux pipelines avec Databricks Jobs selon des horaires quotidiens, incluant le rafraîchissement automatisé des tableaux de bord, et utilisation d'Unity Catalog pour une gestion gouvernée des tables sur les deux projets.

Scoring de risque de défaut de crédit [GitHub]:

- Construction d'un pipeline de scoring de crédit de bout en bout sur le jeu de données Home Credit Default Risk (Kaggle), couvrant l'EDA, le prétraitement et l'ingénierie des caractéristiques sur ~307K demandes de prêt et 122 variables.
- Ingénierie de caractéristiques incluant des ratios financiers, des indicateurs de valeurs manquantes et des agrégations d'historique de crédit du bureau, validées par analyse de corrélation et de multicolinéarité (VIF).
- Entraînement et comparaison de modèles de régression logistique, de forêt aléatoire et de gradient boosting à l'aide des métriques AUROC, Gini, KS et AUPRC.
- Développement d'un pipeline Scikit-learn prêt pour la production et rédaction de documentation de validation de modèle suivant les meilleures pratiques de l'industrie financière.

Highlighted Projects

Détection de fraude par carte de crédit [GitHub]: Développement d'un système de détection de fraude analysant plus de 590K transactions issues du jeu de données IEEE-CIS avec XGBoost. Traitement d'un déséquilibre de classes extrême (taux de fraude de 0,3 %) via SMOTE et ajustement des poids de classe. Conception d'un tableau de bord Power BI pour la surveillance en temps réel des transactions suspectes. Technologies utilisées : Python, XGBoost, SMOTE, scikit-learn, Pandas, Power BI.

Professional Experiences

Ingénieure en apprentissage automatique, Jarvis (2026-présent): Travail dans un environnement de développement Agile basé sur GitFlow, en livrant des projets pratiques d'apprentissage automatique et d'ingénierie des données, incluant la modélisation prédictive, les pipelines ETL et DLT, la segmentation client et l'explicabilité des modèles, avec Python, SQL, Apache Spark, Databricks et des plateformes infonuagiques.

Gestionnaire de l'infrastructure de données, Médecins francophones du Canada (2026-01 à 2026-04): Conception et déploiement de l'architecture de données principale de l'organisation, migration des données historiques vers un environnement SQL structuré. Construction de pipelines ETL automatisés entre CiviCRM et Power BI, réduisant le temps de production des rapports de 80 %. Création de tableaux de bord Power BI interactifs pour l'analyse prédictive des tendances d'adhésion et le suivi des KPI.

Stagiaire en science des données, Francoflex (2025-07 à 2025-12): Développement d'un pipeline ML de bout en bout pour la reconnaissance vocale du français accentué, traitant plus de 3 000 échantillons audio. Amélioration de la précision du modèle de 35 % grâce à des techniques d'augmentation de données. Mise en place d'une infrastructure d'entraînement répliquable avec Python, Docker et MLflow.

Stagiaire en analyse de données, ARSENE (2024-06 à 2024-08): Optimisation de requêtes SQL complexes réduisant les temps d'exécution de 25 %. Réalisation d'analyses de qualité des données identifiant plus de 20 anomalies critiques dans les pipelines ETL. Construction de tableaux de bord internes pour surveiller la qualité des données avec Python et SQL.

Education

Université du Québec à Chicoutimi (UQAC) (2024-2026), Maîtrise en informatique, Informatique - Intelligence artificielle - Spécialisations : Apprentissage automatique, Apprentissage profond, Fouille de données

École d'ingénieurs Polytech Tours (2020-2025), Diplôme d'ingénieur, Génie logiciel - Axes : Big Data, Statistiques, Algorithmes, Bases de données relationnelles

Miscellaneous

- Power BI (DataCamp) : Visualisation de données et maîtrise de DAX
- Détection de fraude en Python (DataCamp) : Application du ML avec XGBoost et SMOTE

- Analyse de données (IBM) : ID 25UDNA8FVK48
- Français (Langue maternelle)
- Anglais (Professionnel - TOEIC 890/990)