

Samia Carchaf . Jarvis Consulting

J'ai récemment complété une maîtrise en informatique avec une spécialisation en intelligence artificielle à l'UQAC, ainsi qu'un diplôme d'ingénieure en génie logiciel de Polytech Tours, et j'ai acquis une expérience concrète en machine learning et en ingénierie de données à travers des projets chez Jarvis Consulting Group. Mon parcours inclut le travail avec Python, SQL, PostgreSQL, Docker, Bash scripting et Linux pour construire des solutions de collecte de données, d'automatisation et d'infrastructure. Je m'intéresse particulièrement à l'utilisation de l'IA et de l'apprentissage automatique pour rendre les processus de développement plus intelligents et efficaces, que ce soit pour automatiser des tâches répétitives ou structurer le travail de manière plus rigoureuse. Je cherche constamment à apprendre, à progresser et à contribuer au mieux au sein de mes équipes, en m'appuyant sur mon expérience technique.

Skills

Proficient: Python, Machine Learning, Linux/Bash, RDBMS/SQL, Docker, Git

Competent: Agile/Scrum, Power BI, Modélisation de données, Databricks, Apache Spark

Familiar: Java, Azure ML, AWS, MLflow, Tableau

Jarvis Projects

Project source code: https://github.com/jarviscanada/jarvis_data_eng_SamiaCarchaf

Surveillance de cluster [GitHub]:

- Conception et implémentation d'un agent de surveillance de cluster Linux pour la collecte des spécifications matérielles et des données d'utilisation des ressources en temps réel des serveurs Linux.
- Provisionnement d'une base de données PostgreSQL avec Docker pour le stockage persistant.
- Automatisation de la collecte continue de données chaque minute via crontab, permettant une surveillance en temps réel du cluster pour l'équipe LCA.

SGBDR et SQL [GitHub]:

- Conception et implémentation d'un schéma de base de données relationnelle avec PostgreSQL, incluant l'application des principes de normalisation et le maintien de l'intégrité des données via clés primaires, clés étrangères et contraintes.
- Rédaction de requêtes SQL optimisées pour répondre à des questions d'affaires.

Analytique de données Python [GitHub]:

- Construction d'un pipeline analytique Python de bout en bout sur la base de données des plaintes consommateurs du CFPB (États-Unis).
- Profilage, nettoyage et ingénierie de variables avec Pandas, incluant la segmentation par catégorie d'entreprise et l'analyse de tendances temporelles.
- Production de visualisations interactives couvrant 7 constats clés, incluant la concentration de marché, l'évolution de la gamme de produits et un tableau de bord de responsabilisation du Bureau à sept dimensions.

Spark [GitHub]:

- Provisionnement d'un cluster Hadoop sur GCP Dataproc et configuration d'une table externe Hive sur HDFS pour le stockage du jeu de données World Development Indicators (WDI, ~21,7M lignes).
- Analyse des tendances historiques de croissance du PIB par pays, incluant l'identification de l'année de croissance maximale du PIB pour chaque pays via des transformations DataFrame.

Databricks [GitHub]:

- Construction d'un pipeline ETL batch dans Azure Databricks pour l'analytique de détection de fraude, incluant l'ingestion des données de transactions, cartes, utilisateurs, marchands et étiquettes de fraude depuis Azure SQL Database et ADLS Gen2 vers une architecture en médaillon Bronze/Silver/Gold, produisant 6 tables gold pour un tableau de bord d'analytique de fraude Databricks.
- Construction d'un pipeline DLT (Lakeflow Declarative Pipelines) pour l'ingestion quotidienne de données boursières depuis l'API Alpha Vantage, avec calcul de métriques de tendance de prix et volume sur 7/30/90 jours via des fonctions de fenêtrage Spark.

- Application du suivi de changements SCD Type 1, conception de tables en streaming vs vues matérialisées selon les modèles de mise à jour des données, et sécurisation des identifiants API via les Databricks secret scopes.
- Orchestration des deux pipelines avec Databricks Jobs sur des horaires quotidiens, incluant le rafraîchissement automatisé du tableau de bord, et utilisation de Unity Catalog pour la gestion gouvernée des tables sur les deux projets.

Scoring de risque de défaut de crédit [GitHub]:

- Construction d'un pipeline de scoring de crédit de bout en bout sur le jeu de données Home Credit Default Risk (Kaggle), couvrant l'EDA, le prétraitement et l'ingénierie de variables sur ~307K demandes de prêt et 122 variables.
- Développement de variables incluant des ratios financiers, des indicateurs de valeurs manquantes et des agrégations d'historique de crédit du bureau, validées par analyse de corrélation et de multicollinéarité (VIF).
- Entraînement et comparaison de modèles de régression logistique, forêt aléatoire et gradient boosting à l'aide des métriques AUROC, Gini, KS et AUPRC.
- Développement d'un pipeline Scikit-learn prêt pour la production et génération d'une documentation de validation de modèle suivant les meilleures pratiques de l'industrie financière.

Highlighted Projects

Détection de fraude par carte de crédit [GitHub]: Développement d'un système de détection de fraude analysant plus de 590K transactions du jeu de données IEEE-CIS avec XGBoost. Traitement d'un déséquilibre de classe extrême (taux de fraude de 0,3%) via SMOTE et ajustement des poids de classe. Conception d'un tableau de bord Power BI pour la surveillance en temps réel des transactions suspectes. Technologies utilisées : Python, XGBoost, SMOTE, scikit-learn, Pandas, Power BI.

Professional Experiences

Ingénieure Machine Learning, Jarvis (2026-présent): Livraison de projets concrets de machine learning et d'ingénierie de données dans un environnement de développement Agile basé sur GitFlow, incluant modélisation prédictive, pipelines ETL et DLT, segmentation de clientèle et explicabilité de modèles, avec Python, SQL, Apache Spark, Databricks et des plateformes infonuagiques.

Responsable de l'infrastructure de données, Médecins francophones du Canada (2026-01 à 2026-04): Conception et déploiement de l'architecture de données centrale de l'organisme, incluant la migration de données historiques vers un environnement SQL structuré. Développement de pipelines ETL automatisés entre CiviCRM et Power BI, réduisant le temps de production des rapports de 80% tout en garantissant l'intégrité des données. Création de tableaux de bord Power BI interactifs pour l'analyse prédictive des tendances d'adhésion et le suivi des indicateurs de performance (KPI).

Scientifique de données, Francoflex (2025-07 à 2025-12): Développement d'un pipeline ML de bout en bout pour la reconnaissance vocale du français accentué, incluant un système d'annotation personnalisé et le traitement de plus de 3K échantillons audio. Amélioration de la précision du modèle et mise en place d'une infrastructure d'entraînement reproductible (Python, Docker, MLflow).

Analyste de données, ARSENE (2024-06 à 2024-08): Optimisation de requêtes SQL complexes, réduisant les temps d'exécution de 25%. Analyse de qualité des données, identification de plus de 20 anomalies critiques dans les pipelines ETL. Création de tableaux de bord internes pour le suivi de la qualité des données (Python, SQL).

Education

Université du Québec à Chicoutimi (UQAC) (2024-2026), Maîtrise en Informatique, Intelligence artificielle - Spécialisations : Machine Learning, Traitement Automatique du Langage Naturel, apprentissage profond, exploration de données

École d'ingénieurs Polytech Tours (2020-2025), Diplôme d'ingénieure, Génie logiciel - Focus : Big Data, statistiques, algorithmes, bases de données relationnelles

Miscellaneous

- Power BI (DataCamp) : visualisation de données et maîtrise de DAX
- Détection de fraude en Python (DataCamp) : application ML avec XGBoost et SMOTE

- Analyse de données (IBM) : ID 25UDNA8FVK48
- Français (langue maternelle)
- Anglais (professionnel - TOEIC 890/990)